Гаркавый Андрей, 494 группа

Задание - пройти контест на Kaggle.

In [22]:
```
from sklearn.model_selection import TimeSeriesSplit
from sklearn.ensemble import BaggingRegressor, RandomForestRegressor, GradientBoostingRegressor
from sklearn.neighbors import KNeighborsRegressor
from sklearn.tree import DecisionTreeRegressor
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
```

In [2]:
```
train = pd.read_csv("train.tsv")
test = pd.read_csv("test.tsv")
sample_submission = pd.read_csv("sample_submission.tsv")
```

In [3]:
```
train.head()
```

Out[3]:

	Num	y	year	week	shift	item_id	f1	f2	f3	f4	...	f51	f52	f53	f54	f55	f56
0	0	123438	2012	52	1	20442076	4915.0	38056.0	40185.0	45733.0	...	39423.0	41765.0	52590.0	31452.0	44420.0	4186
1	1	58410	2012	52	1	20441997	2230.0	18817.0	20110.0	26368.0	...	22830.0	25230.0	27850.0	21390.0	27090.0	2317
2	2	163930	2012	52	1	20441990	5695.0	47480.0	47619.0	89708.0	...	14930.0	44290.0	46412.0	29320.0	21140.0	2840
3	3	53902	2012	52	1	20441989	1995.0	17146.0	20066.0	27070.0	...	15120.0	12480.0	19780.0	7990.0	8230.0	1065
4	4	105970	2012	52	1	20441988	6515.0	49262.0	50045.0	95167.0	...	18872.0	19328.0	37168.0	13570.0	19760.0	2020

5 rows × 66 columns

In [4]:
```
test.head()
```

Out[4]:

	Num	year	week	shift	item_id	f1	f2	f3	f4	f5	...	f51	f52	f53	f54
0	348622	2015	3	3	20447918	960.0	820.0	1128.0	1801.0	1045.0	...	1510.0	580.0	969.0	1635.0
1	348623	2015	3	3	20447902	9086.0	12585.0	11595.0	9685.0	12917.0	...	22055.0	14235.0	21195.0	18280.0
2	348624	2015	3	3	20447732	115087.0	147287.0	176065.0	143105.0	202069.0	...	302165.0	162232.0	221622.0	256605.0
3	348625	2015	3	3	20443951	20900.0	24420.0	27068.0	20460.0	25580.0	...	39055.0	14445.0	22450.0	22093.0
4	348626	2015	3	3	20443944	4430.0	5864.0	3310.0	1853.0	2836.0	...	120.0	130.0	60.0	30.0

5 rows × 65 columns

In [5]:
```
sample_submission.head()
```

Out[5]:

	Num	y
0	348622	198575.912031
1	348623	198575.912031
2	348624	198575.912031
3	348625	198575.912031
4	348626	198575.912031

In [148]:
```
frac = 0.05

train_part = train.sample(frac=frac, random_state=42)
train_part = train_part.sort_values(['year', 'week'], ascending=[1, 1])

X = train_part.drop(['Num', 'y'], axis=1)
y = train_part['y']
```

Будем работать с 5% выборки.

In [149]:
```
X.head()
```

Out[149]:

	year	week	shift	item_id	f1	f2	f3	f4	f5	f6	...	f51	f52	f53	f54
127	2012	52	1	20438572	20650.0	198032.0	215778.0	260442.0	351795.0	212581.0	...	196921.0	183287.0	239261.0	14980
176	2012	52	1	20438332	8020.0	71982.0	78962.0	112012.0	150403.0	80233.0	...	72251.0	75669.0	112764.0	48416.
128	2012	52	1	20438581	0.0	0.0	0.0	10.0	0.0	10.0	...	10.0	10.0	0.0	10.0
35	2012	52	1	20440742	0.0	0.0	20.0	30.0	20.0	15.0	...	0.0	0.0	10.0	0.0
212	2012	52	1	20438687	3870.0	38538.0	42185.0	43778.0	57285.0	32580.0	...	34150.0	37630.0	49825.0	27780.

5 rows × 64 columns

In [150]:
```
y.head()
```

Out[150]:
```
127    485643
176    222073
128       177
35         32
212     98145
Name: y, dtype: int64
```

In [14]:
```
def smape(y_true, y_pred):
    return np.mean(np.abs((y_true - y_pred) / (abs(y_true) + abs(y_pred)))) * 200
```

In [15]:
```
def score_model(model, X, y):
    tscv = TimeSeriesSplit(n_splits=5)
    cross_val_score = []
    for train_index, test_index in tscv.split(X):
        # print("TRAIN:", train_index, "TEST:", test_index)
        X_train, X_test = X.iloc[train_index, :], X.iloc[test_index, :]
        y_train, y_test = y.iloc[train_index], y.iloc[test_index]
        model.fit(X_train, y_train)
        preds = model.predict(X_test)

        cross_val_score.append(smape(y_test, preds))
    cross_val_score = np.array(cross_val_score)
    score = cross_val_score.mean()
    return score
```

Написали функцию для вычисления кросс-валидации по времени на наших данных.

In [151]:
```
print(score_model(GradientBoostingRegressor(n_estimators=100, max_depth=5, random_state=43), X, y))
print(score_model(GradientBoostingRegressor(n_estimators=100, max_depth=10, random_state=44), X, y))
```

```
42.0652490825
35.550399101
```

In [152]:
```
f = X.shape[1]
print(score_model(DecisionTreeRegressor(max_features=int(f ** 0.5)), X, y))
```

```
42.2848688338
```

In [153]:
```
print(score_model(BaggingRegressor(DecisionTreeRegressor()), X, y))
```

```
32.2154991918
```

In [154]:
```
print(score_model(BaggingRegressor(DecisionTreeRegressor(max_features=int(f ** 0.5))), X, y))
```

```
33.8987945987
```

In [155]:
```
print(score_model(RandomForestRegressor(), X, y))
```

```
32.722747705
```

In [156]:
```
print(score_model(BaggingRegressor(RandomForestRegressor()), X, y))
```

```
33.0592496799
```

Проверили несколько регрессоров: самые лучшие - это BaggingRegressor(DecisionTreeRegressor() и RandomForestRegressor(). Если отправить RandomForestRegressor, обученный на всей выборке, получаем SMAPE 24 с чем-то, это неплохо, это лучший мой результат.

In [157]:
```
plt.figure(figsize=(18, 6))
plt.plot(np.arange(1, 61), [X['f' + str(i)].iloc[0] for i in np.arange(1, 61)])
plt.scatter([61], [y.iloc[0]])
plt.show()
```

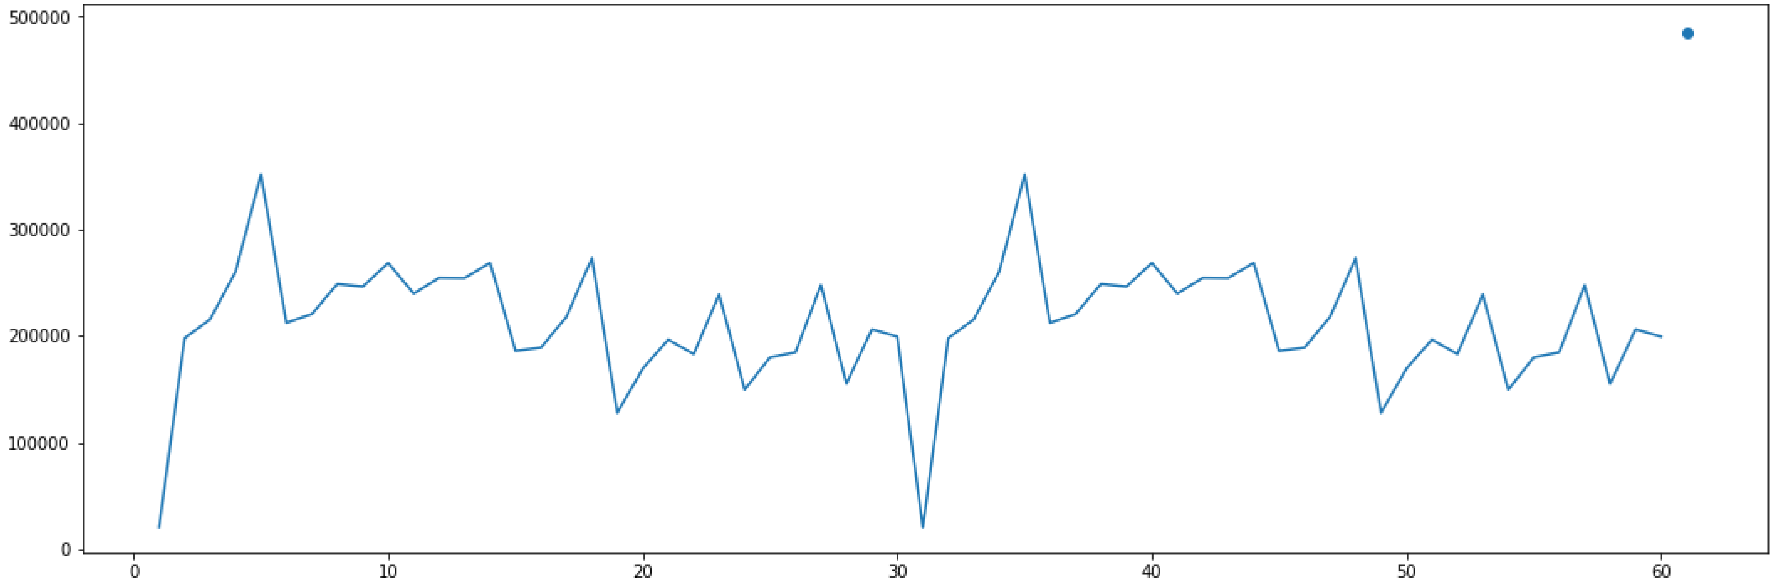

Если нарисовать данные, видно, что первая половина f1...f30 повторяет вторую f31..f60. Выкинем половину.

In [158]:
```
X = X[['f' + str(i) for i in np.arange(1, 31)] + ['year', 'week', 'shift', 'item_id']]
X.head()
```

Out[158]:

	f1	f2	f3	f4	f5	f6	f7	f8	f9	f10	...	f25	f26	f27
127	20650.0	198032.0	215778.0	260442.0	351795.0	212581.0	220787.0	249000.0	246481.0	268937.0	...	180159.0	184969.0	2479
176	8020.0	71982.0	78962.0	112012.0	150403.0	80233.0	101056.0	102723.0	108437.0	138153.0	...	71649.0	87808.0	1269
128	0.0	0.0	0.0	10.0	0.0	10.0	0.0	10.0	0.0	10.0	...	10.0	10.0	40.0
35	0.0	0.0	20.0	30.0	20.0	15.0	0.0	5.0	0.0	5.0	...	0.0	0.0	10.0
212	3870.0	38538.0	42185.0	43778.0	57285.0	32580.0	35460.0	38701.0	39796.0	50395.0	...	33270.0	39875.0	4238

5 rows × 34 columns

In [160]:
```
plt.figure(figsize=(18, 6))
plt.plot(np.arange(1, 31), [X['f' + str(i)].iloc[np.arange(0, 3)] for i in np.arange(1, 31)])
plt.scatter([31], [y.iloc[0]])
plt.scatter([31], [y.iloc[1]])
plt.scatter([31], [y.iloc[2]])
plt.show()
```

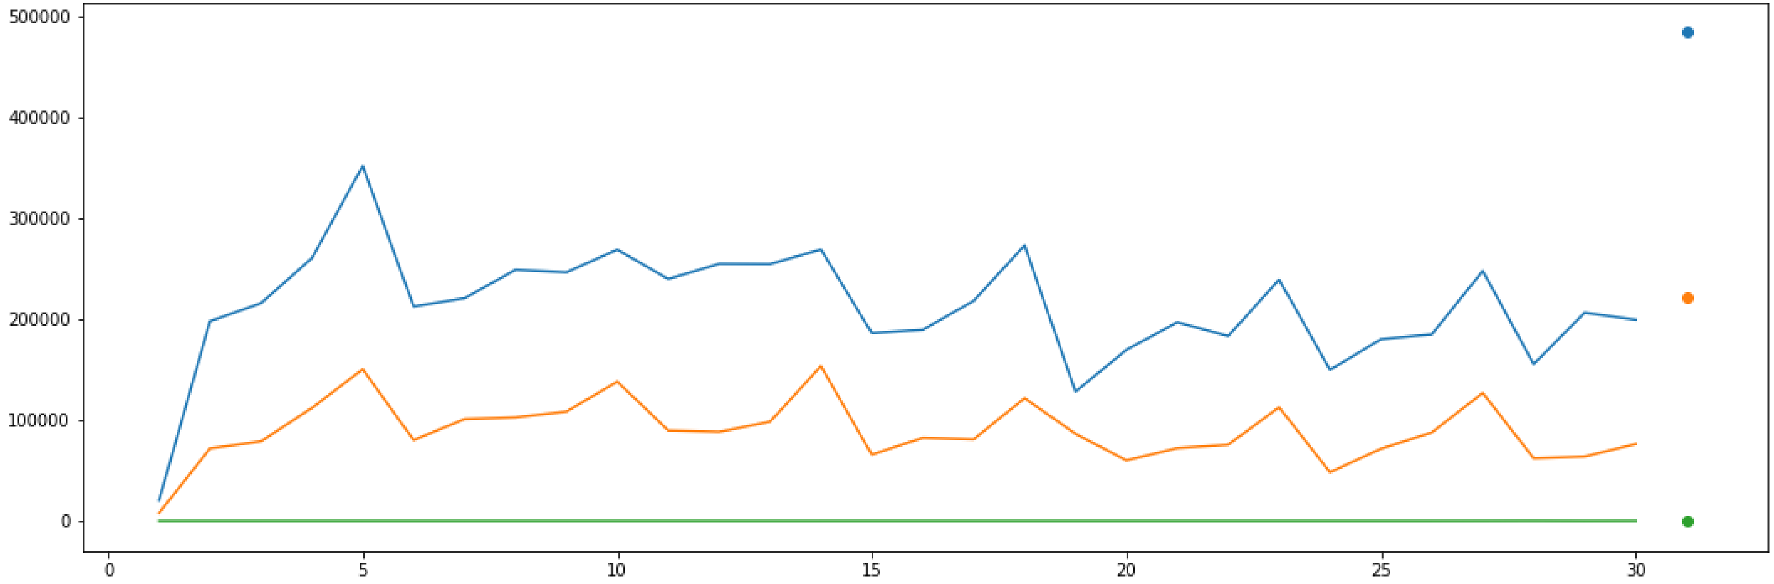

Можно заметить, что значение y 0 - очень похоже на последнюю f. В условии сказано, что это продажи в какие-то периоды времени этого товара, похоже, то чем больше f - тем ближе к нужной неделе.

In [161]:
```
C = 0.4
n = 8
plt.figure(figsize=(18, 6))
plt.plot(np.arange(1, 31), [X['f' + str(i)].iloc[np.arange(0, n)] for i in np.arange(1, 31)])
for i in np.arange(0, n):
    plt.scatter([31], [y.iloc[i] * C])
plt.show()
```

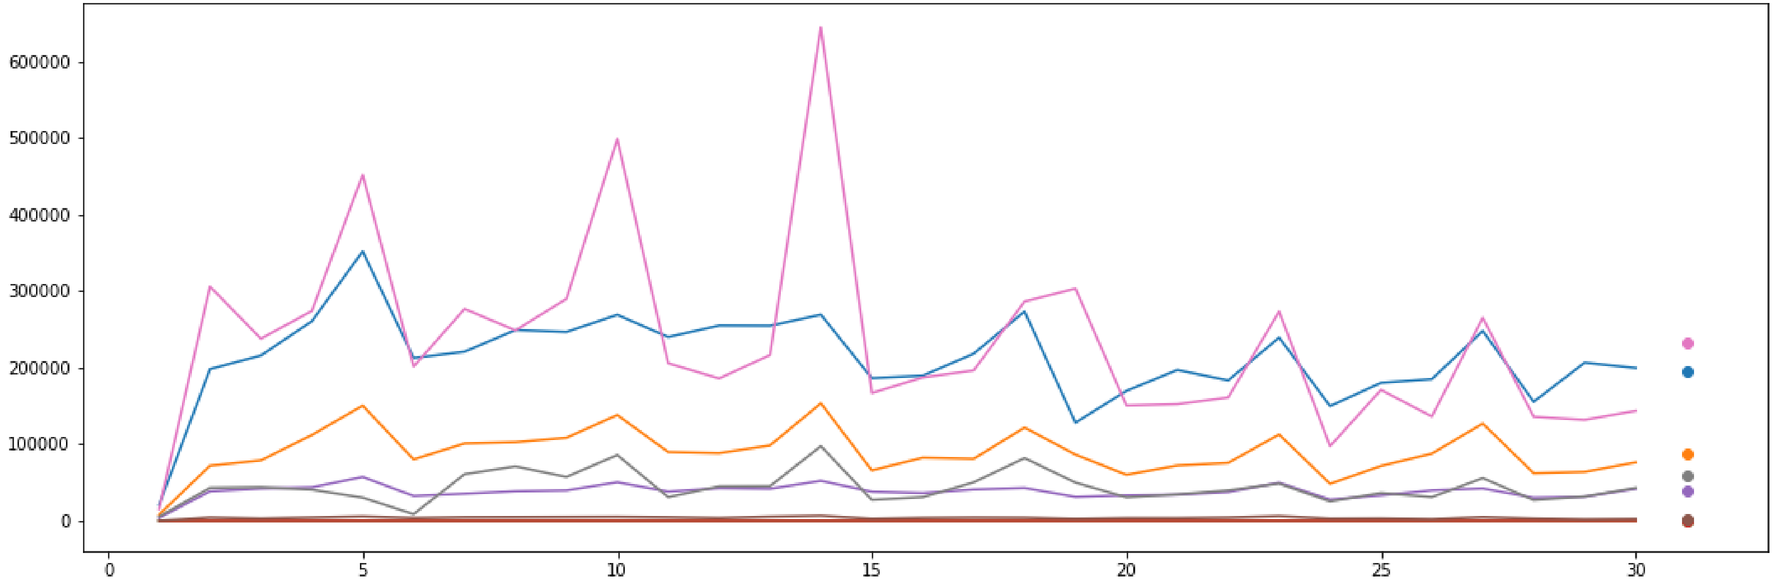

Если домножить на коэффициент, действительно, видим, что y - около f30. Поэтому разумно обучать только на последних элементах выборки.

In [171]:
```
ns = [1, 5, 10, 15, 20, 21, 22, 23, 24, 25, 26, 27, 28, 29, 30]
rf_scores = []
for n in ns:
    rf_scores.append(score_model(RandomForestRegressor(),
                                 X[['f' + str(i) for i in np.arange(n, 31)] +
                                   ['year', 'week', 'shift', 'item_id']], y))
```

In [172]:
```
plt.figure(figsize=(17, 4))
plt.plot(ns, np.array(rf_scores))
plt.show()
```

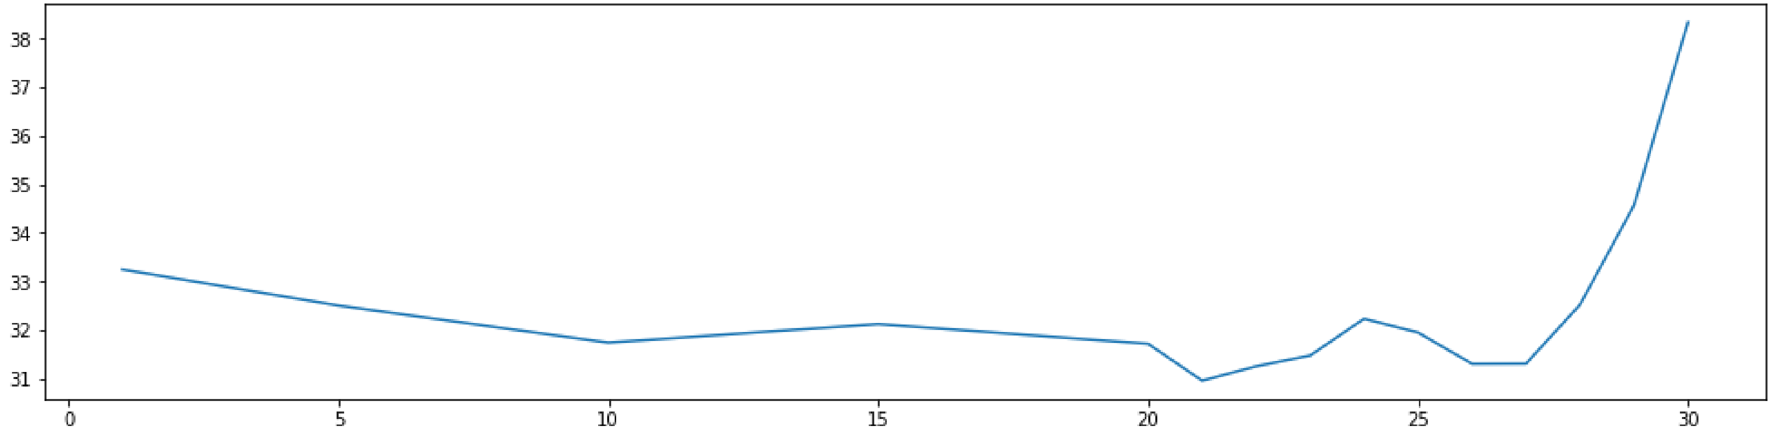

Давайте выкинем данные до f_n, переберем n. Надо взять n около 21.

In [173]:
```
rf_scores
```

Out[173]:
```
[33.248894358863701,
 32.507210083460173,
 31.744576839527888,
 32.125825317476327,
 31.720579341110316,
 30.961565384271204,
 31.257566824930354,
 31.479390408555112,
 32.235177769808118,
 31.951708084870511,
 31.309131958598101,
 31.312646505153833,
 32.525127361363545,
 34.569716621202339,
 38.336367556095986]
```

In [174]:
```
dt_scores = []
for n in ns:
    dt_scores.append(score_model(BaggingRegressor(DecisionTreeRegressor()),
                                 X[['f' + str(i) for i in np.arange(n, 31)] +
                                   ['year', 'week', 'shift', 'item_id']], y))
```

In [175]:
```
plt.figure(figsize=(17, 4))
plt.plot(ns, np.array(dt_scores))
plt.show()
```

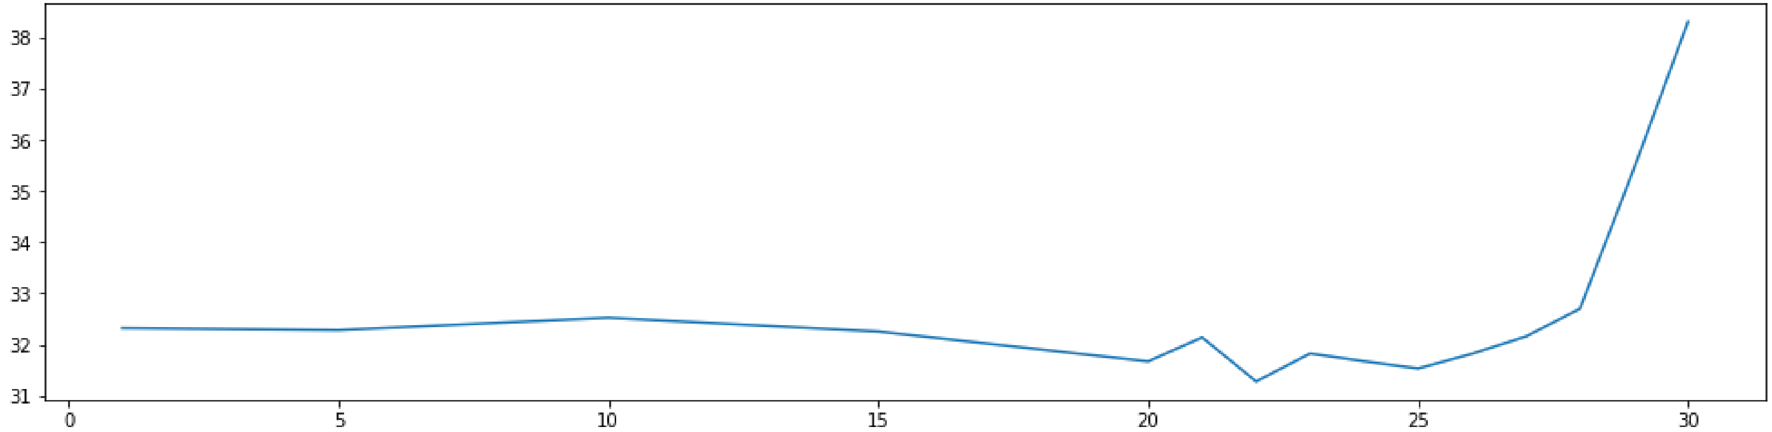

И для DecisionTreeRegressor, и для RandomForestRegressor мы видим, что n надо выбирать около 21. Возьмем 21.

In [176]:
```
dt_scores
```

Out[176]:
```
[32.319635959538495,
 32.279930481395198,
 32.5218424387064,
 32.252378198309103,
 31.667921950084871,
 32.137087067077346,
 31.274733159897561,
 31.821903939554851,
 31.670511703313132,
 31.528124404771212,
 31.817580543870349,
 32.155845043074471,
 32.699666906892595,
 35.445972662429888,
 38.313875979420558]
```

In [190]:
```
X_train = train[['f' + str(i) for i in range(21, 31)] + ['year', 'week', 'shift', 'item_id']]
X_train.head()
```

Out[190]:

	f21	f22	f23	f24	f25	f26	f27	f28	f29	f30	year	week	shift	item_id
0	39423.0	41765.0	52590.0	31452.0	44420.0	41865.0	52705.0	36102.0	44163.0	45239.0	2012	52	1	20442076
1	22830.0	25230.0	27850.0	21390.0	27090.0	23170.0	29705.0	19140.0	22055.0	23200.0	2012	52	1	20441997
2	14930.0	44290.0	46412.0	29320.0	21140.0	28406.0	65056.0	31886.0	48750.0	36520.0	2012	52	1	20441990
3	15120.0	12480.0	19780.0	7990.0	8230.0	10650.0	21920.0	13040.0	9780.0	9630.0	2012	52	1	20441989
4	18872.0	19328.0	37168.0	13570.0	19760.0	20208.0	34745.0	18442.0	24700.0	21793.0	2012	52	1	20441988

In [191]:
```
X_test = test[['f' + str(i) for i in range(21, 31)] + ['year', 'week', 'shift', 'item_id']]
X_test.head()
```

Out[191]:

	f21	f22	f23	f24	f25	f26	f27	f28	f29	f30	year	week	shift	item_id
0	1510.0	580.0	969.0	1635.0	895.0	2140.0	1182.0	1020.0	1293.0	1290.0	2015	3	3	20447918
1	22055.0	14235.0	21195.0	18280.0	18270.0	15851.0	16920.0	18320.0	24116.0	21307.0	2015	3	3	20447902
2	302165.0	162232.0	221622.0	256605.0	240047.0	236630.0	206697.0	245652.0	286179.0	285904.0	2015	3	3	20447732
3	39055.0	14445.0	22450.0	22093.0	31175.0	23355.0	15358.0	18930.0	29643.0	33970.0	2015	3	3	20443951
4	120.0	130.0	60.0	30.0	50.0	20.0	20.0	30.0	0.0	0.0	2015	3	3	20443944

In [192]:
```
model = RandomForestRegressor()
model.fit(X_train, train['y'])
preds = model.predict(X_test)
```

In [193]:
```
sample_submission['y'] = preds
sample_submission.head(5)
```

Out[193]:

	Num	y
0	348622	2794.1
1	348623	27311.6
2	348624	314837.5
3	348625	32043.4
4	348626	17.6

In [194]:
```
sample_submission['y'] = sample_submission['y'].map(lambda x: x if x > 0 else 0.0)
```

In [195]:
```
sample_submission.to_csv("garkavyy_clever_random_forest_submission.tsv", sep=',', index=False)
```

Итоговый SMAPE мы получили 26, что еще хуже, очень грустно, но что поделать.